

KI für Wissenschaft und Medizin: Chancen, Zuverlässigkeit und valide Evaluationsprotokolle

Faik Hadutoglu, Nico Lang, Nicolaj Schmid

Abstract—

Index Terms—Künstliche Intelligenz, Medizin, Diagnostik, Reproduzierbarkeit, Bias, Fairness, MDR, Human-AI-Teaming

I. EINLEITUNG

KÜNSTLICHE Intelligenz (KI) beschreibt die Fähigkeit technischer Systeme, menschliche Denkprozesse wie logisches Denken, Lernen, Planen und Kreativität nachzuahmen. Sie ermöglicht Maschinen, ihre Umgebung wahrzunehmen, die gewonnenen Informationen zu verarbeiten und daraus eigenständig Entscheidungen abzuleiten, um definierte Ziele zu erreichen. Durch die Analyse großer Datenmengen können KI-Systeme ihr Verhalten an Erfahrungen anpassen und zunehmend autonom agieren [1]. Mit dem wachsenden Einsatz von KI in der Medizin entstehen neue Möglichkeiten für die Analyse medizinischer Daten - insbesondere in der Diagnostik, der Planung von Therapien sowie in der Unterstützung von Kommunikation und Dokumentation im Gesundheitswesen [2].

Aktuelle Erhebungen des Digitalverbands Bitkom in Kooperation mit dem Hartmannbund - dem Verband der Ärztinnen und Ärzte Deutschlands - zeigen, dass sich der Einsatz von KI in deutschen Krankenhäusern seit 2022 innerhalb von drei Jahren nahezu verdoppelt hat. KI wird dabei nicht nur in administrativen Bereichen, etwa zur Praxisverwaltung, eingesetzt, sondern zunehmend auch unmittelbar im medizinischen Kontext - beispielsweise zur Unterstützung bei Diagnosen oder der Analyse von Vitaldaten (siehe Abbildung 1) [3].

Darüber hinaus befürworten 67 % der befragten Ärztinnen und Ärzte eine gezielte Förderung des KI-Einsatzes in der Medizin. Gleichzeitig sehen 78 % in KI eine große Chance für die zukünftige Entwicklung der Medizin, während 76 % zugleich eine strenge Regulierung fordern, um Sicherheit und Qualität zu gewährleisten. Diese ambivalente Haltung verdeutlicht sowohl das Potenzial als auch die bestehenden Unsicherheiten beim Einsatz von KI im medizinischen Kontext [3].

Vor diesem Hintergrund stellt sich die zentrale Forschungsfrage, wie die Zuverlässigkeit KI-gestützter Diagnosen und wissenschaftlicher Entdeckungen valide und systematisch bewertet werden kann. Dabei gilt es zu klären, welche methodischen Standards, Evaluationsprotokolle und regulatorischen Rahmenbedingungen erforderlich sind, um Reproduzierbarkeit, Fairness und Transparenz zu gewährleisten – insbesondere im Hinblick auf die europäischen Vorgaben der Medizinprodukteverordnung (MDR).

Studiengang Fahrzeugelektronik (TFE23-2), DHBW Ravensburg.

KI bereits in fast jeder siebten Praxis

Welche Angebote werden in Ihrer Praxis eingesetzt? Welche halten Sie für sinnvoll?




Fig. 1. [3] KI-Nutzung in Arztpraxen 2025 | Quelle: Bitkom Research, 2025

Dieses Paper verfolgt das Ziel, aktuelle wissenschaftliche Ansätze zur Validierung von KI-Systemen in der Medizin kritisch zu beleuchten und Kriterien für vertrauenswürdige, reproduzierbare und faire KI-basierte Entscheidungsprozesse herauszuarbeiten. NOTE: IN WELCHEM KAPITEL WURDE ES KURZ BEXCHRIEBEN

II. WIE FUNKTIONIERT KÜNSTLICHE INTELLIGENZ

Die Funktionsweise moderner Systeme der Künstlichen Intelligenz (KI) basiert im Kern auf der Fähigkeit, große Datenmengen zu verarbeiten und darin Muster sowie statistische Zusammenhänge zu erkennen. Ein zentrales Konzept hierbei sind künstliche neuronale Netze, die dem Aufbau biologischer Neuronen nachempfunden sind und Informationen in mehreren hierarchischen Schichten verarbeiten [4].

Neuronale Netze bestehen aus einem Input-Layer, mehreren Hidden-Layers und einem Output-Layer¹. Jede Schicht wandelt die Aktivierungen der vorherigen Schicht mithilfe gewichteter Verbindungen um, sodass unterschiedliche Muster repräsentiert werden können [4]. Während des Trainingsprozesses werden die Gewichte zwischen den Neuronen schrittweise angepasst, sodass das Netzwerk zunehmend aussagekräftige Merkmalsrepräsentationen lernt und schließlich in der Lage ist, Muster zu erkennen und zu generalisieren [4].

Dieser Prozess hängt jedoch entscheidend von der Qualität der Trainingsdaten ab. Neuronale Netze lernen ausschließlich aus den Mustern in ihren Daten - sie können daher nur so zuverlässig sein wie die Daten, auf denen sie trainiert

¹Der Output-Layer ist die letzte Schicht des Netzwerks und produziert die endgültige Vorhersage oder Entscheidung. Bei einer medizinischen Diagnose könnte der Output-Layer beispielsweise eine Wahrscheinlichkeit zwischen 0 und 1 ausgeben, die anzeigt, ob eine bestimmte Krankheit vorhanden ist oder nicht.

wurden [6]. Diese Abhängigkeit von guter Datenqualität ist entscheidend, um die Zuverlässigkeit KI-gestützter Diagnosen zu verstehen und zeigt, warum strenge Validierungsverfahren notwendig sind.

III. CHANCEN VON KI IN WISSENSCHAFT UND MEDIZIN

Künstliche Intelligenz (KI) hat sich zu einem zentralen Werkzeug in biomedizinischer Forschung und moderner Patientenversorgung entwickelt. Besonders datengetriebene Verfahren des maschinellen Lernens und Deep Learning werden inzwischen routinemäßig für Bildanalyse, Prognosemodelle und wissenschaftliche Auswertungen eingesetzt [8].

A. Grundbegriffe und Anwendungsfelder

Unter *Machine Learning* (ML) werden Modelle verstanden, die aus Beispieldaten statistische Zusammenhänge lernen, anstatt über explizite Regeln programmiert zu werden. *Deep Learning* (DL) bezeichnet ML-Methoden mit tiefen neuronalen Netzen und ist insbesondere für Bild-, Text- und Sequenzdaten relevant [8]. In der Medizin werden solche Modelle typischerweise in klinischen Entscheidungsunterstützungssystemen genutzt, die Diagnosen, Risikoprognosen oder Therapieentscheidungen ergänzen [8].

Typische Anwendungsfelder sind:

- **Bildgebende Diagnostik:** In Radiologie und Pathologie analysieren DL-Modelle Röntgen-, CT- und MRT-Daten oder histologische Schnitte, markieren auffällige Regionen und unterstützen bei der Befundung [8].
- **Klinische Prognose und Risikobewertung:** ML-Modelle verarbeiten tabellarische klinische Daten, Laborwerte oder Vitalparameter, um Komplikations- oder Rehospitalisierungsrisiken abzuschätzen [8].
- **Biomedizinische Forschung:** Modellfamilien für Proteinsequenzen und -strukturen (z.B. AlphaFold, ESM3) sowie multimodale Modelle unterstützen die Identifikation neuer Zielstrukturen und Wirkstoffkandidaten [8].

Im Fokus dieses Beitrags stehen datengetriebene KI-Systeme, die auf großen medizinischen oder biomedizinischen Datensätzen trainiert werden und in Diagnostik, Prognose und Forschung Anwendung finden [8].

B. Chancen und Nutzen

Die beschriebenen Systeme eröffnen eine Vielzahl konkreter Potenziale für Wissenschaft und medizinische Praxis.

a) *Steigerung der diagnostischen Qualität:* Mehrere aktuelle klinische Studien zeigen, dass KI-Modelle in bestimmten diagnostischen Bildgebungsaufgaben vergleichbare oder sogar bessere Leistungen als Expert:innen erzielen [8] [?]. Besonders vielversprechend sind Human-AI-Teams, da sich deren Diagnosegenauigkeit in Studien teils als überlegen gegenüber Einzelentscheidungen erwiesen hat [8].

b) *Präzisionsmedizin und neue wissenschaftliche Einsichten:* Große Modellarchitekturen für Proteinstrukturen und biologische Sequenzen ermöglichen es, komplexe Zusammenhänge in Omics-Daten besser zu erfassen und Strukturinformationen in bisher unerreichtem Umfang zu generieren [8]. Dadurch werden neue Hypothesen in Biologie und

Pharmakologie möglich, beispielsweise bei der Suche nach geeigneten Wirkstoffbindestellen.

c) *Effizienzgewinne und Entlastung klinischer Teams:* Ökonomische Analysen deuten darauf hin, dass KI in vielen medizinischen Sektoren messbare Produktivitätsgewinne ermöglicht, insbesondere durch Automatisierung repetitiver Tätigkeiten wie Vorbefundung, Triage und Dokumentation [8]. Synthetische Daten werden als innovative Möglichkeit für datenschutzkonforme Trainingsdatensätze und das Abbilden seltener Szenarien diskutiert [8].

d) *Gesellschaftlicher Nutzen und Akzeptanz:* Befragungen zeigen, dass viele Menschen KI-Anwendungen als nützlich wahrnehmen und deren Einfluss auf Alltag und Gesundheit erwarten; jedoch besteht weiterhin Skepsis bezüglich ethischer Standards und der Realisierbarkeit versprochener Vorteile [8].

IV. RISIKEN UND WISSENSCHAFTLICHE HERAUSFORDERUNGEN

Mit dem zunehmenden Einsatz von KI in sicherheitskritischen Kontexten steigen die Anforderungen an Qualität und Transparenz der zugrunde liegenden Studien. Klassische Leistungskennzahlen nähern sich inzwischen teils der Sättigung, gleichzeitig bleiben zentrale Fragen zu Robustheit, Fairness und langfristigem Verhalten vieler Systeme offen [8].

A. Reproduzierbarkeit von KI-Ergebnissen

Reproduzierbarkeit bedeutet, dass unabhängige Gruppen unter ähnlichen Bedingungen zu kongruenten Ergebnissen gelangen. Für medizinische KI umfasst das:

- transparente Beschreibung von Datensätzen und deren Vorverarbeitung,
- robuste Evaluationsprotokolle mit externer Validierung,
- nachvollziehbare Dokumentation der Modellarchitektur und Hyperparameter [8].

Da immer mehr KI-Systeme reale Behandlungsentscheidungen beeinflussen, sind diese Standards essenziell für Patient:innensicherheit und evidenzbasierten Einsatz.

B. Bias und Fairness

Bias kann auftreten, wenn Vorhersagen systematisch bestimmte Gruppen benachteiligen, etwa aufgrund einseitiger Trainingsdaten oder ungeeigneter Zielgrößen [9] [8]. Das Vertrauen, dass KI diskriminierungsfrei agiert, ist laut Umfragen gesunken. Wissenschaftliche Studien mahnen daher, Leistungsvergleiche in relevanten Subgruppen (Geschlecht, Alter, Ethnie) zu berichten und Zielgrößen kritisch zu wählen [9] [8].

C. Transparenz und Erklärbarkeit (Explainable AI)

Viele leistungsfähige Modelle verhalten sich für Nutzer:innen wie Black Boxes. Deshalb sind Transparenz auf Systemebene (Trainingsdaten, Modellgrenzen, Evaluationsprotokolle) und Erklärbarkeit auf Fallniveau (z.B. Heatmaps, Feature Attribution) entscheidend [11] [8]. Human-AI-Teams profitieren dann am meisten, wenn

die Nutzerinnen die Stärken und Schwächen des Modells einschätzen können.

Transparenz und Erklärbarkeit sind somit nicht nur ethische Anforderungen, sondern essenzielle Bedingungen für eine sichere Integration in den Versorgungsalltag [8] [11].

V. VALIDE STUDIEN UND EVALUATIONSPROTOKOLLE

A. Datenbasis und Studiendesign

B. Evaluationsmetriken für diagnostische KI

C. Vergleich mit Expert:innen und klinische Studien

D. Dokumentation und Reproduzierbarkeit

VI. REGULATORISCHE UND ETHISCHE RAHMENBEDINGUNGEN

A. KI als Medizinprodukt und die EU-MDR

B. Datenschutz und ethische Aspekte

VII. HUMAN-AI-TEAMING IN DER MEDIZINISCHEN PRAXIS

A. Rollenverteilung zwischen Mensch und KI

B. Vertrauen, Akzeptanz und Usability

VIII. FAZIT UND AUSBLICK

ACKNOWLEDGMENT

REFERENCES

- [1] Europäisches Parlament, "Was ist künstliche Intelligenz und wie wird sie genutzt?" Generaldirektion Kommunikation, 2023. [Online]. Verfügbar unter: <https://www.europarl.europa.eu/news/de/headlines/priorities/kunstliche-intelligenz-in-der-eu/20230601STO93804/ki-gesetz-erste-regulierung-der-kunstlichen-intelligenz> (letzter Zugriff: 05.11.2025).
- [2] Bundesärztekammer, "Von ärztlicher Kunst mit Künstlicher Intelligenz: Künstliche Intelligenz in der Medizin," Positionspapier, 2025. [Online]. Available: <https://www.bundesaerztekammer.de/themen/aerzte/digitalisierung/ki-in-der-medizin> (letzter Zugriff: 05.11.2025).
- [3] Bitkom e.V. und Hartmannbund, "KI in fast jeder siebten Praxis und vielen Kliniken im Einsatz," Presseinformation, 27. Mai 2025. [Online]. Verfügbar unter: <https://www.bitkom.org/Presse/Presseinformation/KI-in-Praxis-und-Kliniken-im-Einsatz> [Zugriff am: 10. Nov. 2025].
- [4] Grüning, Alexander, "Künstliche Neuronale Netze – Grundlagen und Entwicklungen; Künstliche Intelligenz; Einführung in die Künstliche Intelligenz*, Vorlesungspräsentationen, DHBW, unveröffentlichtes Lehrmaterial, 2025.
- [5] F. Schmiedchen, M. Hafner, A. von Gernler und K. P. Kratzer (Hrsg.), *Künstliche Intelligenz und Wir: Stand, Nutzung und Herausforderungen der KI*. Springer Vieweg, Berlin, 2026. [Online]. Verfügbar unter: <https://doi.org/10.1007/978-3-662-71567-3> (letzter Zugriff: 17.11.2025).
- [6] S. Mohammed, L. Budach, M. Feuerpfeil, N. Ihde, A. Nathansen, N. Noack, H. Patzlaff, F. Naumann und H. Harmouch, "The effects of data quality on machine learning performance on tabular data," *Information Systems*, vol. 132, 2025, Art. Nr. 102549, ISSN 0306-4379. [Online]. Verfügbar unter: <https://www.sciencedirect.com/science/article/pii/S0306437925000341> (letzter Zugriff: 05.11.2025).
- [7] Grant Sanderson, "Gradient descent, how neural networks learn," 3Blue1Brown, 2017. [Online]. Verfügbar unter: <https://www.3blue1brown.com/topics/neural-networks> (letzter Zugriff: 16.11.2025).
- [8] Stanford Institute for Human-Centered Artificial Intelligence (HAI), *Artificial Intelligence Index Report 2025*. Stanford University, 2025. [Online]. Verfügbar unter: <https://aiindex.stanford.edu> (letzter Zugriff: 05.11.2025).
- [9] Celi, L. A., Cellini, J., Charpignon, M.-L., Dee, E. C., Démoncourt, F., Eber, R., Mitchell, W. G., Moukheiber, L., Schirmer, J., Situ, J., Paguio, J., Park, J., Wawira, J. G., Yao, S., & for MIT Critical Data, "Sources of bias in artificial intelligence that perpetuate health disparities," *PLOS Digital Health*, 2022. [Online]. Verfügbar unter: <https://journals.plos.org/digitalhealth/article?id=10.1371/journal.pdig.0000022> (letzter Zugriff: 05.11.2025).
- [10] Faiyazuddin, M., Rahman, S. J. Q., Anand, G., Siddiqui, R. K., Mehta, R., Khatib, M. N., Gaidhane, S., Zahiruddin, Q. S., Hussain, A., & Sah, R., "The Impact of Artificial Intelligence on Healthcare," *National Library of Medicine*, 2025. [Online]. Verfügbar unter: <https://pubmed.ncbi.nlm.nih.gov/articles/PMC11702416/> (letzter Zugriff: 05.11.2025).
- [11] Chen, H., Gomez, C., Huang, C.-M., & Unberath, M., "Explainable medical imaging AI needs human-centered design," *Nature*, 2022. [Online]. Verfügbar unter: <https://www.nature.com/articles/s41746-022-00699-2> (letzter Zugriff: 05.11.2025).