

KI für Wissenschaft und Medizin: Chancen, Zuverlässigkeit und valide Evaluationsprotokolle

Faik Hadutoglu, Nico Lang, Nicolaj Schmid

Abstract—

Index Terms—Künstliche Intelligenz, Medizin, Diagnostik, Reproduzierbarkeit, Bias, Fairness, MDR, Human-AI-Teaming

I. EINLEITUNG

KÜNSTLICHE Intelligenz (KI) beschreibt die Fähigkeit technischer Systeme, menschliche Denkprozesse wie logisches Denken, Lernen, Planen und Kreativität nachzuahmen. Sie ermöglicht Maschinen, ihre Umgebung wahrzunehmen, die gewonnenen Informationen zu verarbeiten und daraus eigenständig Entscheidungen abzuleiten, um definierte Ziele zu erreichen. Durch die Analyse großer Datenmengen können KI-Systeme ihr Verhalten an Erfahrungen anpassen und zunehmend autonom agieren [1]. Mit dem wachsenden Einsatz von KI in der Medizin entstehen neue Möglichkeiten für die Analyse medizinischer Daten - insbesondere in der Diagnostik, der Planung von Therapien sowie in der Unterstützung von Kommunikation und Dokumentation im Gesundheitswesen [2].

Aktuelle Erhebungen des Digitalverbands Bitkom in Kooperation mit dem Hartmannbund - dem Verband der Ärztinnen und Ärzte Deutschlands - zeigen, dass sich der Einsatz von KI in deutschen Krankenhäusern seit 2022 innerhalb von drei Jahren nahezu verdoppelt hat. KI wird dabei nicht nur in administrativen Bereichen, etwa zur Praxisverwaltung, eingesetzt, sondern zunehmend auch unmittelbar im medizinischen Kontext - beispielsweise zur Unterstützung bei Diagnosen oder der Analyse von Vitaldaten (siehe Abbildung 1) [3].

Darüber hinaus befürworten 67 % der befragten Ärztinnen und Ärzte eine gezielte Förderung des KI-Einsatzes in der Medizin. Gleichzeitig sehen 78 % in KI eine große Chance für die zukünftige Entwicklung der Medizin, während 76 % zugleich eine strenge Regulierung fordern, um Sicherheit und Qualität zu gewährleisten. Diese ambivalente Haltung verdeutlicht sowohl das Potenzial als auch die bestehenden Unsicherheiten beim Einsatz von KI im medizinischen Kontext [3].

Vor diesem Hintergrund stellt sich die zentrale Forschungsfrage, wie die Zuverlässigkeit KI-gestützter Diagnosen und wissenschaftlicher Entdeckungen valide und systematisch bewertet werden kann. Dabei gilt es zu klären, welche methodischen Standards, Evaluationsprotokolle und regulatorischen Rahmenbedingungen erforderlich sind, um Reproduzierbarkeit, Fairness und Transparenz zu gewährleisten – insbesondere im Hinblick auf die europäischen Vorgaben der Medizinprodukteverordnung (MDR).

Studiengang Fahrzeugelektronik (TFE23-2), DHBW Ravensburg.

KI bereits in fast jeder siebten Praxis

Welche Angebote werden in Ihrer Praxis eingesetzt? Welche halten Sie für sinnvoll?




Fig. 1. [3] KI-Nutzung in Arztpraxen 2025 | Quelle: Bitkom Research, 2025

Dieses Paper verfolgt das Ziel, aktuelle wissenschaftliche Ansätze zur Validierung von KI-Systemen in der Medizin kritisch zu beleuchten und Kriterien für vertrauenswürdige, reproduzierbare und faire KI-basierte Entscheidungsprozesse herauszuarbeiten. NOTE: IN WELCHEM KAPITEL WURDE ES KURZ BEXCHRIEBEN

II. WIE FUNKTIONIERT KÜNSTLICHE INTELLIGENZ

Die Funktionsweise moderner Systeme der Künstlichen Intelligenz (KI) basiert im Kern auf der Fähigkeit, große Datenmengen zu verarbeiten und darin Muster sowie statistische Zusammenhänge zu erkennen. Ein zentrales Konzept hierbei sind künstliche neuronale Netze, die dem Aufbau biologischer Neuronen nachempfunden sind und Informationen in mehreren hierarchischen Schichten verarbeiten [4].

Neuronale Netze bestehen aus einem Input-Layer, mehreren Hidden-Layers und einem Output-Layer. Jede Schicht wandelt die Aktivierungen der vorherigen Schicht mithilfe gewichteter Verbindungen um, sodass unterschiedliche Muster repräsentiert werden können [4]. Beispielsweise werden bei der Bildverarbeitung die Eingabedaten eines neuronalen Netzes als Vektor aus Pixelintensitäten dargestellt. Jedes Pixel entspricht dabei einem Eingabeneuron und erhält abhängig von seiner Helligkeit einen numerischen Wert. Ein Bild mit einer Auflösung von 28×28 Pixeln wird somit zu einem 784-dimensionalen Spaltenvektor transformiert, der dem Netzwerk als Input dient. Die gewichtete Summe der Eingangsaktivierungen bestimmt dabei die Aktivierung eines Neurons in der nächsten Schicht. Während des Trainingsprozesses werden die Gewichte zwischen den Neuronen schrittweise angepasst, sodass das zunächst „dumme“ Netzwerk zunehmend aussagekräftige Merkmalsrepräsentationen lernt und schließlich in der Lage ist, Muster - wie etwa handgeschriebene Ziffern




Fig. 2. [4] Darstellung eines vollständig verbundenen neuronalen Netzes zur Klassifikation handgeschriebener Ziffern.

- zu "erkennen"(siehe Abb. 2). Dieses Vorgehen basiert im Allgemeinen auf dem grundlegenden Prinzip, dass neuronale Netze durch iterative Gewichtsoptimierung aus Beispieldaten abstrahieren und eigenständig Muster erlernen [4].

Der Lernprozess eines neuronalen Netzes besteht darin, die Gewichte zwischen den Neuronen so anzupassen, dass relevante Merkmale in den Daten verstärkt und irrelevante abgeschwächt werden. Um das Netzwerk möglichst effizient zu optimieren, gibt es verschiedene Optimierungsverfahren. Eine der bekanntesten Methoden ist die Gradientenmethode.

Bei einem einzelnen Neuron lässt sich die Kostenfunktion¹ $C(w)$ zwei-dimensional darstellen, wobei die x-Achse das Gewicht w und die y-Achse den Fehler abbildet (siehe 3). In diesem Fall kann das Minimum analytisch berechnet werden. Bei mehreren Neuronen steigt die Dimensionalität: Mit zwei Neuronen entsteht ein dreidimensionales, mit drei Neuronen ein vierdimensionales Problem. Obwohl sich diese hochdimensionalen Räume nicht visualisieren lassen, können mathematische Optimierungen durchgeführt werden.

Das Gradientenverfahren funktioniert nach folgendem Prinzip: Die Gewichte werden zunächst zufällig initialisiert. Alle Gewichte werden in einem Vektor $\mathbf{w}$ zusammengefasst, und der Gradient $\nabla f(\mathbf{w})$ dieses Vektors wird berechnet, welcher die Richtung des steilsten Anstiegs anzeigt. Um zum Minimum zu gelangen, geht man in die entgegengesetzte Richtung $-\nabla f(\mathbf{w})$. In dieser Richtung werden iterativ kleine Schritte der Größe Δx durchgeführt, um das Minimum schrittweise anzunähern(siehe 3). Durch diesen iterativen Anpassungsprozess verbessert das Netzwerk schrittweise seine internen Repräsentationen und erzeugt zunehmend zuverlässigere und präzisere Ausgaben.

Allerdings hängt dieser Lernprozess entscheidend von der Qualität der zugrunde liegenden Trainingsdaten ab. Während neuronale Netze darauf ausgelegt sind, aus Beispieldaten verallgemeinerbare Muster zu lernen, setzt dies voraus, dass die Daten korrekt, ausgewogen und repräsentativ sind. In realen Anwendungen ist dies jedoch selten gegeben: Trainingsdaten enthalten häufig Ungleichverteilungen, fehlerhafte oder inkonsistente Labels sowie strukturelle Verzerrungen, die das Modell unbewusst mitlernt. Da neuronale Netze ausschließlich

¹Die Kostenfunktion $C(w)$ beschreibt, wie stark die Vorhersagen des Netzes von den tatsächlichen Zielwerten abweichen und quantifiziert damit den Fehler für die gegebenen Gewichte.




Fig. 3. [4]Eindimensionale Kostenfunktion mit einem Gewicht (links) und hochdimensionale Kostenfunktion mit zwei Gewichten (rechts) mit lokalen Minima.

statistische Regelmäßigkeiten aus den vorliegenden Daten extrahieren, ohne deren Ursprung oder Validität zu hinterfragen, reproduzieren sie systematisch auch solche unerwünschten Muster. Diese Form der fehlerhaften oder unausgewogenen Informationsaufnahme wird als Bias bezeichnet. Bias kann unterschiedliche Ausprägungen haben: Sampling Bias entsteht, wenn bestimmte Gruppen in den Daten über- oder unterrepräsentiert sind und das Modell dadurch verzerrte Verteilungen lernt; Measurement Bias ergibt sich aus ungenauen, inkonsistenten oder gruppenspezifisch verzerrten Mess- und Annotierungsprozessen; und Technical Bias entsteht durch technische Artefakte wie unterschiedliche Bildauflösungen, Scannerparameter oder Aufnahmebedingungen, die vom Modell irrtümlich als relevante Merkmale interpretiert werden. Diese Verzerrungen sind damit keine nachgelagerten Effekte, sondern eine direkte Folge des datengetriebenen Lernprozesses: Alles, was in den Trainingsdaten enthalten ist - einschließlich ihrer systematischen Fehler -, wird durch die Optimierung verstärkt und prägt die späteren Vorhersagen des Modells. Dadurch können insbesondere in der medizinischen Diagnostik bestimmte Patientengruppen schlechter erkannt werden oder Entscheidungen auf scheinbar statistischen, tatsächlich aber klinisch irrelevanten Zusammenhängen beruhen.

Zusammenfassend beruht der Lernprozess künstlicher Intelligenz auf der iterativen Anpassung interner Modellparameter anhand umfangreicher, jedoch unvermeidbar fehlerbehafteter Datenbestände. Dieses grundlegende Prinzip ist zentral für die Leistungsfähigkeit moderner KI-Systeme, bringt jedoch zugleich erhebliche Herausforderungen im Hinblick auf Zuverlässigkeit, Fairness und Reproduzierbarkeit mit sich.

III. CHANCEN VON KI IN WISSENSCHAFT UND MEDIZIN

Künstliche Intelligenz (KI) hat sich zu einem zentralen Werkzeug in biomedizinischer Forschung und moderner Patientenversorgung entwickelt. Besonders datengetriebene Verfahren des maschinellen Lernens und Deep Learning werden inzwischen routinemäßig für Bildanalyse, Prognosemodelle und wissenschaftliche Auswertungen eingesetzt [7].

A. Grundbegriffe und Anwendungsfelder

Unter *Machine Learning* (ML) werden Modelle verstanden, die aus Beispieldaten statistische Zusammenhänge lernen, anstatt über explizite Regeln programmiert zu werden. *Deep Learning* (DL) bezeichnet ML-Methoden mit tiefen neuronalen Netzen und ist insbesondere für Bild-, Text- und

Sequenzdaten relevant [7]. In der Medizin werden solche Modelle typischerweise in klinischen Entscheidungsunterstützungssystemen genutzt, die Diagnosen, Risikoprognosen oder Therapieentscheidungen ergänzen [7].

Typische Anwendungsfelder sind:

- **Bildgebende Diagnostik:** In Radiologie und Pathologie analysieren DL-Modelle Röntgen-, CT- und MRT-Daten oder histologische Schnitte, markieren auffällige Regionen und unterstützen bei der Befundung [7].
- **Klinische Prognose und Risikobewertung:** ML-Modelle verarbeiten tabellarische klinische Daten, Laborwerte oder Vitalparameter, um Komplikations- oder Rehospitalisierungsrisiken abzuschätzen [7].
- **Biomedizinische Forschung:** Modellfamilien für Proteinsequenzen und -strukturen (z. B. AlphaFold, ESM3) sowie multimodale Modelle unterstützen die Identifikation neuer Zielstrukturen und Wirkstoffkandidaten [7].

Im Fokus dieses Beitrags stehen datengetriebene KI-Systeme, die auf großen medizinischen oder biomedizinischen Datensätzen trainiert werden und in Diagnostik, Prognose und Forschung Anwendung finden [7].

B. Chancen und Nutzen

Die beschriebenen Systeme eröffnen eine Vielzahl konkreter Potenziale für Wissenschaft und medizinische Praxis.

a) *Steigerung der diagnostischen Qualität:* Mehrere aktuelle klinische Studien zeigen, dass KI-Modelle in bestimmten diagnostischen Bildgebungsaufgaben vergleichbare oder sogar bessere Leistungen als Expert:innen erzielen [7] [?]. Besonders vielversprechend sind Human-AI-Teams, da sich deren Diagnosegenauigkeit in Studien teils als überlegen gegenüber Einzelentscheidungen erwiesen hat [7].

b) *Präzisionsmedizin und neue wissenschaftliche Einsichten:* Große Modellarchitekturen für Proteinstrukturen und biologische Sequenzen ermöglichen es, komplexe Zusammenhänge in Omics-Daten besser zu erfassen und Strukturinformationen in bisher unerreichtem Umfang zu generieren [7]. Dadurch werden neue Hypothesen in Biologie und Pharmakologie möglich, beispielsweise bei der Suche nach geeigneten Wirkstoffbindestellen.

c) *Effizienzgewinne und Entlastung klinischer Teams:* Ökonomische Analysen deuten darauf hin, dass KI in vielen medizinischen Sektoren messbare Produktivitätsgewinne ermöglicht, insbesondere durch Automatisierung repetitiver Tätigkeiten wie Vorbefundung, Triage und Dokumentation [7]. Synthetische Daten werden als innovative Möglichkeit für datenschutzkonforme Trainingsdatensätze und das Abbilden seltener Szenarien diskutiert [7].

d) *Gesellschaftlicher Nutzen und Akzeptanz:* Befragungen zeigen, dass viele Menschen KI-Anwendungen als nützlich wahrnehmen und deren Einfluss auf Alltag und Gesundheit erwarten; jedoch besteht weiterhin Skepsis bezüglich ethischer Standards und der Realisierbarkeit versprochener Vorteile [7].

IV. RISIKEN UND WISSENSCHAFTLICHE HERAUSFORDERUNGEN

Mit dem zunehmenden Einsatz von KI in sicherheitskritischen Kontexten steigen die Anforderungen an Qualität und Transparenz der zugrunde liegenden Studien. Klassische Leistungskennzahlen nähern sich inzwischen teils der Sättigung, gleichzeitig bleiben zentrale Fragen zu Robustheit, Fairness und langfristigem Verhalten vieler Systeme offen [7].

A. Reproduzierbarkeit von KI-Ergebnissen

Reproduzierbarkeit bedeutet, dass unabhängige Gruppen unter ähnlichen Bedingungen zu kongruenten Ergebnissen gelangen. Für medizinische KI umfasst das:

- transparente Beschreibung von Datensätzen und deren Vorverarbeitung,
- robuste Evaluationsprotokolle mit externer Validierung,
- nachvollziehbare Dokumentation der Modellarchitektur und Hyperparameter [7].

Da immer mehr KI-Systeme reale Behandlungsentscheidungen beeinflussen, sind diese Standards essenziell für Patient:innensicherheit und evidenzbasierten Einsatz.

B. Bias und Fairness

Bias kann auftreten, wenn Vorhersagen systematisch bestimmte Gruppen benachteiligen, etwa aufgrund einseitiger Trainingsdaten oder ungeeigneter Zielgrößen [8] [7]. Das Vertrauen, dass KI diskriminierungsfrei agiert, ist laut Umfragen gesunken. Wissenschaftliche Studien mahnen daher, Leistungsvergleiche in relevanten Subgruppen (Geschlecht, Alter, Ethnie) zu berichten und Zielgrößen kritisch zu wählen [8] [7].

C. Transparenz und Erklärbarkeit (Explainable AI)

Viele leistungsfähige Modelle verhalten sich für Nutzer:innen wie Black Boxes. Deshalb sind Transparenz auf Systemebene (Trainingsdaten, Modellgrenzen, Evaluationsprotokolle) und Erklärbarkeit auf Fallniveau (z.B. Heatmaps, Feature Attribution) entscheidend [10] [7]. Human-AI-Teams profitieren dann am meisten, wenn die Nutzer:innen die Stärken und Schwächen des Modells einschätzen können.

Transparenz und Erklärbarkeit sind somit nicht nur ethische Anforderungen, sondern essenzielle Bedingungen für eine sichere Integration in den Versorgungsalltag [7] [10].

V. VALIDE STUDIEN UND EVALUATIONSPROTOKOLLE

- A. *Datenbasis und Studiendesign*
- B. *Evaluationsmetriken für diagnostische KI*
- C. *Vergleich mit Expert:innen und klinische Studien*
- D. *Dokumentation und Reproduzierbarkeit*

VI. REGULATORISCHE UND ETHISCHE RAHMENBEDINGUNGEN

- A. *KI als Medizinprodukt und die EU-MDR*
- B. *Datenschutz und ethische Aspekte*

VII. HUMAN-AI-TEAMING IN DER MEDIZINISCHEN PRAXIS

- A. *Rollenverteilung zwischen Mensch und KI*
- B. *Vertrauen, Akzeptanz und Usability*

VIII. FAZIT UND AUSBLICK

ACKNOWLEDGMENT

REFERENCES

- [1] Europäisches Parlament, "Was ist künstliche Intelligenz und wie wird sie genutzt?" Generaldirektion Kommunikation, 2023. [Online]. Verfügbar unter: <https://www.europarl.europa.eu/news/de/headlines/priorities/kunstliche-intelligenz-in-der-eu/20230601STO93804/ki-gesetz-erste-regulierung-der-kunstlichen-intelligenz> (letzter Zugriff: 05.11.2025).
- [2] Bundesärztekammer, "Von ärztlicher Kunst mit Künstlicher Intelligenz: Künstliche Intelligenz in der Medizin," Positionspapier, 2025. [Online]. Available: <https://www.bundesaerztekammer.de/themen/aerzte/digitalisierung/ki-in-der-medizin> (letzter Zugriff: 05.11.2025).
- [3] Bitkom e.V. und Hartmannbund, „KI in fast jeder siebten Praxis und vielen Kliniken im Einsatz,“ Presseinformation, 27. Mai 2025. [Online]. Verfügbar unter: <https://www.bitkom.org/Presse/Presseinformation/KI-in-Praxis-und-Kliniken-im-Einsatz> [Zugriff am: 10. Nov. 2025].
- [4] Grüning, Alexander, *Künstliche Neuronale Netze – Grundlagen und Entwicklungen; Künstliche Intelligenz; Einführung in die Künstliche Intelligenz*, Vorlesungspräsentationen, DHBW, unveröffentlichtes Lehrmaterial, 2025.
- [5] F. Schmiedchen, M. Hafner, A. von Gernler und K. P. Kratzer (Hrsg.), *Künstliche Intelligenz und Wir: Stand, Nutzung und Herausforderungen der KI*. Springer Vieweg, Berlin, 2026. [Online]. Verfügbar unter: <https://doi.org/10.1007/978-3-662-71567-3> (letzter Zugriff: 17.11.2025).
- [6] Grant Sanderson, "Gradient descent, how neural networks learn," 3Blue1Brown, 2017. [Online]. Verfügbar unter: <https://www.3blue1brown.com/topics/neural-networks> (letzter Zugriff: 16.11.2025).
- [7] Stanford Institute for Human-Centered Artificial Intelligence (HAI), *Artificial Intelligence Index Report 2025*. Stanford University, 2025. [Online]. Verfügbar unter: <https://aiindex.stanford.edu> (letzter Zugriff: 05.11.2025).
- [8] Celi, L. A., Cellini, J., Charpignon, M.-L., Dee, E. C., Derroncourt, F., Eber, R., Mitchell, W. G., Moukheiber, L., Schirmer, J., Situ, J., Paguio, J., Park, J., Wawira, J. G., Yao, S., & for MIT Critical Data, „Sources of bias in artificial intelligence that perpetuate health disparities,“ *PLOS Digital Health*, 2022. [Online]. Verfügbar unter: <https://journals.plos.org/digitalhealth/article?id=10.1371/journal.pdig.0000022> (letzter Zugriff: 05.11.2025).
- [9] Faiyazuddin, M., Rahman, S. J. Q., Anand, G., Siddiqui, R. K., Mehta, R., Khatib, M. N., Gaidhane, S., Zahiruddin, Q. S., Hussain, A., & Sah, R., „The Impact of Artificial Intelligence on Healthcare,“ *National Library of Medicine*, 2025. [Online]. Verfügbar unter: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11702416/> (letzter Zugriff: 05.11.2025).
- [10] Chen, H., Gomez, C., Huang, C.-M., & Unberath, M., „Explainable medical imaging AI needs human-centered design,“ *Nature*, 2022. [Online]. Verfügbar unter: <https://www.nature.com/articles/s41746-022-00699-2> (letzter Zugriff: 05.11.2025).